

# Auditoria do método de avaliação

## O que dá para confiar antes de trocar de modelo — e o que não dá

Thiago José Nunes

23 de setembro de 2026

### 1. A resposta direta

O método tinha quatro defeitos. **Três eu corriji. O quarto é o mais grave e só você pode resolver.**

E ele é decisivo: **do jeito que o conjunto de teste está hoje, o modelo novo vai empatar com o SFace.** Não porque seja igual, mas porque o teste não consegue separar os dois. Trocar de modelo com base nesta nota seria decidir no escuro.

### 2. Sobre o seu 0,440

Você baixou o limiar para 0,440 e funcionou melhor. **A sua evidência é melhor que a minha.**

Eu calibrei 0,45 comparando as três fotos IMG\_1128/1129/1130 entre si. São três selfies tiradas na mesma sessão, com o mesmo celular. Achar uma a partir da outra é quase reconhecer uma cópia — tarefa fácil.

Olhando as fotos que você enviou pela página, vi o que você estava realmente testando: você subiu **fotos do evento** (IMG\_3008, IMG\_3012, IMG\_3016, IMG\_3020, IMG\_2993) e pediu para achar aquelas pessoas nas outras fotos. Essa é a tarefa do produto — mesma pessoa, ângulos diferentes, distâncias diferentes, luz diferente — e é muito mais difícil.

Nessas consultas aparecem casos exatamente na faixa onde o limiar decide:

| Consulta           | Resultado | Similaridade | Passa em 0,44? | Passa em 0,45? |
|--------------------|-----------|--------------|----------------|----------------|
| pessoa de IMG_3008 | IMG_3214  | 0,4780       | sim            | sim            |
| pessoa de IMG_3008 | IMG_3004  | 0,4605       | sim            | sim            |
| pessoa de IMG_3008 | IMG_3028  | 0,4235       | <b>não</b>     | não            |
| pessoa de IMG_3016 | IMG_3213  | 0,4628       | sim            | sim            |

Meu gabarito não tem **nenhum** caso nessa faixa. Ele nunca poderia ter apontado o 0,44. Você achou olhando o problema real; eu calibrei olhando um problema fácil.

### 3. Os quatro defeitos

#### Defeito 1 — o gabarito testa a tarefa errada (GRAVE, aberto)

O gabarito tem uma pessoa, três fotos, todas selfies da mesma sessão. E essa pessoa **não estava no evento**.

Isso significa que o teste mede "achar uma selfie a partir de outra selfie", quando o produto precisa de "achar a pessoa em fotos de evento, de longe, de lado, com outra iluminação". São dificuldades diferentes. Um modelo pode ir muito bem numa e mal na outra.

**Consequência medida:** no conjunto atual o SFace tira nota máxima em tudo que mede qualidade — AUC 1,000, mAP 1,000, zero intrusos. Não sobra espaço para o modelo novo ser melhor. A comparação passaria a ser decidida só pela velocidade.

Isto não se conserta com métrica melhor. Só com conjunto mais difícil.

#### Defeito 2 — o limiar era calibrado e avaliado nos mesmos dados (CORRIGIDO)

Eu escolhi 0,45 usando o gabarito e depois anunciei  $F1 = 1,000$  medido no mesmo gabarito. O resultado estava garantido por construção — é o erro clássico de "treinar no teste".

**Correção:** validação cruzada. O limiar que julga uma consulta é calibrado **sem** ver essa consulta. Nas três consultas,  $F1 = 1,000$  com limiares 0,4465, 0,4506 e 0,4506. Agora é uma estimativa honesta, e não uma tautologia.

#### Defeito 3 — a nota dependia da escala de similaridade (CORRIGIDO)

A nota antiga media  $F1$  num limiar. Mas o cosseno do SFace vai de  $-1$  a  $1$  e uma API paga pode devolver 0 a 100. Comparar modelos num mesmo número não compara nada.

**Correção:** a maior parte da nota agora vem da **ordem** do ranking, que não depende de escala nenhuma:

| Componente | Pontos | O que é                                |
|------------|--------|----------------------------------------|
| Ordenação  | 40     | mAP — os acertos ficaram no topo?      |
| Separação  | 25     | fração dos erros abaixo do pior acerto |
| Robustez   | 15     | $F1$ na validação cruzada              |
| Busca      | 10     | milissegundos                          |
| Indexação  | 10     | segundos por foto                      |

Também troquei a medida de separação. A antiga (d-prime, " $\sigma$ ") divide pelo desvio-padrão dos erros e pressupõe uma distribuição bem comportada — com 3583 rostos de estranhos, não é. A nova só conta: *que fração dos erros ficou abaixo do pior acerto?* Não supõe nada e continua comparável entre modelos.

## Defeito 4 — o código não fazia o que o documento prometia (CORRIGIDO)

O SISTEMA-DE-PONTUACAO.md afirmava que cada modelo seria avaliado no seu melhor limiar. A função existia (`scoring.melhor_limiar`) e **nunca era chamada**: a nota saía no limiar passado na linha de comando. Erro meu, de ligação.

**Correção:** o melhor limiar de cada consulta agora é calculado e aparece no relatório. E a nota de comparação nem depende mais dele.

## 4. O que foi verificado e está bom

- **Tempo é confiável.** Três medições da indexação: 0,1901 / 0,1905 / 0,1901 s por foto — 0,2% de variação. A oscilação que eu tinha visto antes (0,12 a 0,27) era mudança de código, não ruído. Como a velocidade pode acabar decidindo o empate, era importante confirmar isso.
- **A exclusão da auto-correspondência funciona.** A foto de consulta casando consigo mesma não entra em nenhuma métrica.
- **Fotos que o detector perdeu contam como erro.** Foto que existia e não foi indexada entra como perdida, não é ignorada — é o que o visitante sente.
- **O diagnóstico do conjunto avisa sozinho** quando o teste está saturado ou com amostra pequena. Hoje ele avisa as duas coisas.

## 5. O que fazer antes de trocar de modelo

O gabarito precisa conter a tarefa real. Isso quer dizer: **pessoas que estavam no evento, aparecendo em várias fotos diferentes.**

Não precisa ser grande. Com **4 a 6 pessoas do evento**, cada uma marcada nas fotos em que aparece, o conjunto passa a ter casos difíceis — e aí a nota volta a significar alguma coisa.

O trabalho é marcar. Para cada pessoa escolhida:

1. escolha uma foto dela como consulta;
2. rode a busca;
3. percorra o ranking de cima para baixo e marque quais são realmente ela;
4. desça até onde as similaridades ficarem claramente baixas.

A parte boa: como o ranking já vem ordenado, você não olha 204 fotos por pessoa — olha as 15 ou 20 primeiras.

Depois disso, três coisas mudam:

- o limiar passa a ser calibrado na tarefa certa (e provavelmente confirma o seu 0,44 em vez do meu 0,45);
- a nota volta a discriminar, porque vão existir casos que um modelo acerta e o outro erra;
- o TCC pode afirmar precisão sobre o problema real, não sobre selfies.

## 6. O que a nota diz hoje

**YuNet + SFace — 97,8 / 100**, com dois avisos que o próprio relatório imprime:

CONJUNTO SATURADO: todos os acertos ficaram acima de todos os erros. Um modelo melhor vai empatar aqui — a nota passa a ser decidida só pela velocidade.

AMOSTRA PEQUENA: 6 acertos esperados no total. Uma foto a mais ou a menos muda a métrica em dezenas de pontos percentuais.

Leia a nota junto com os avisos. Sozinha, ela parece dizer que o modelo é quase perfeito. Com os avisos, ela diz a verdade: **o modelo passou num teste fácil.**